

spaCy

Extração de Informação

André Câmara (acan@cesar.school)





Agenda

- 1. Introdução
- 2. Abordagens
- 3. Demonstração
- 4. Exercício

Introdução

Sequence Labeling

- A idéia é ir além do problema de classificação padrão
 - Casos individuais são desconectados e independentes (i.i.d.: independently and identically distributed)
- Utilizar informação dos padrões na ordem em que são observados
- Cada token possui um "label" a ele associado
 - Labels são dependentes dos seus vizinhos

Sequence Labelling

Problema

Dado uma **sequência** de *tokens*, inferir qual a sequência **mais provável** de labels para estes *tokens*

Exemplos:

Part of Speech Tagging

Slot Filling (chatbots)

Named Entity Recognition

Part Of Speech Tagging

Nível mais baixo de análise sintática

```
John saw the saw and decided to take it to the table. PN V Det N Con V Part V Pro Prep Det N
```

Utilizado para análises subsequentes

Extração de informação

- Identificação de dados relevantes nos textos
- Encontrar informações específicas
 - PESSOAS, ORGANIZAÇÕES, etc.
- Transformar de um texto em um banco de dados
 - Extrai informações relevantes baseando-se no domínio de conhecimento do documento
 - Exemplo:

MAKE MODEL YEAR MILEAGE PRICE For sale, 2002 Toyota Prius, 20,000 mi, \$15K or best offer. Available starting July 30, 2006.

Texto Livre

4 de abril em Dallas – cedo na noite passada, um tornado varreu todo o noroeste da área de Dallas, causando extensos danos. Testemunhas confirmam que o ciclone passou sem advertência, aproximadamente às 7:15 da noite, e destruiu dois *motor-homes*. O posto Texaco, na Rua Principal, 102, Farmers Branch, TX, também foi severamente danificado, mas nenhuma morte foi informada. O valor total calculado dos danos é de U\$200.000.





Sistema de Extração de Informações

Template

Evento: tornado Data: 4/4/2000 Hora: 19:15

Local: Farmers Branch: "noroeste de Dallas": TX: USA

Danos: "motor-homes" (2): "Posto Texaco" (1)

Perdas Estimadas: U\$200.000

Mortes: nenhuma

Extração de Informação

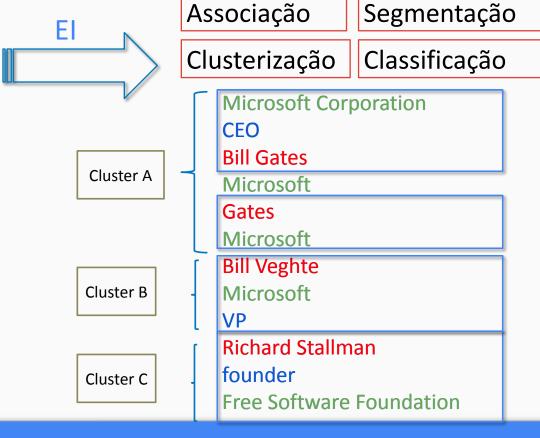
October 14, 2002, 4:00 a.m. PT

For years, Microsoft Corporation CEO Bill Gates railed against the economic philosophy of open-source software with Orwellian fervor, denouncing its communal licensing as a "cancer" that stifled technological innovation.

Today, Microsoft claims to "love" the opensource concept, by which software code is made public to encourage improvement and development by outside programmers. <u>Gates</u> himself says <u>Microsoft</u> will gladly disclose its crown jewels—the coveted code behind the Windows operating system—to select customers.

"We can be open source. We love the concept of shared source," said <u>Bill Veghte</u>, a <u>Microsoft VP</u>. "That's a super-important shift for us in terms of code access."

Richard Stallman, founder of the Free Software Foundation, countered saying...



Extração de Informação

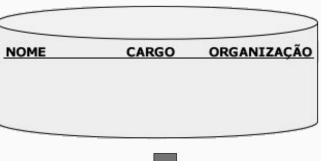
October 14, 2002, 4:00 a.m. PT

For years, Microsoft Corporation CEO Bill Gates railed against the economic philosophy of open-source software with Orwellian fervor, denouncing its communal licensing as a "cancer" that stifled technological innovation.

Today, Microsoft claims to "love" the opensource concept, by which software code is made public to encourage improvement and development by outside programmers. <u>Gates</u> himself says <u>Microsoft</u> will gladly disclose its crown jewels—the coveted code behind the Windows operating system—to select customers.

"We can be open source. We love the concept of shared source," said <u>Bill Veghte</u>, a <u>Microsoft VP</u>. "That's a super-important shift for us in terms of code access."

Richard Stallman, founder of the Free Software Foundation, countered saying...





NOME	CARGO	ORGANIZAÇÃO
Bill Gates	CEO	Microsoft
Bill Veghte	VP	Microsoft
Richard Stallman	founder	Free Software Foundation

Principais abordagens

- 1. Rule-based models (REGEX, FSA, ...)
- 2. Token classification
- 3. Probabilistic Sequence models (HMM, MEMM, CRF)
- 4. Neural networks

Autômatos Finitos

Bons para textos estruturados.

Definidos manualmente ou aprendidos automaticamente.

Tipos:

- Acceptors: com resposta sim ou não
- Recognizers: um ou mais estados finais (categorização)

Chapman/np killed/vbn John/np Lennon/np John/np Lennon/np was/bedz shot/vbd by/by Chapman/np He/pps witnessed/vbd Lennon/np killed/vbn by/by Chapman/np

```
VB - Verb, base form

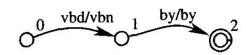
VBD - Verb, past tense

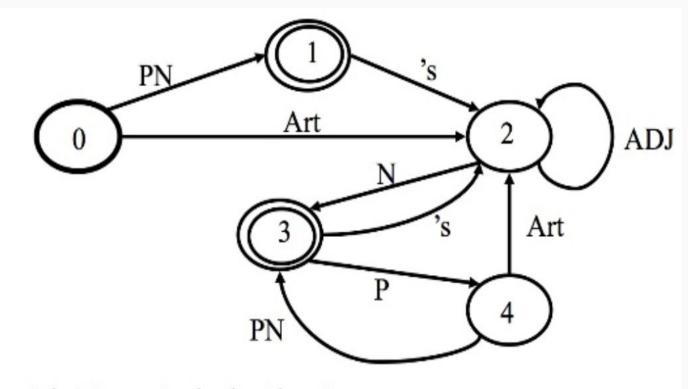
VBG - Verb, gerund or present participle

VBN - Verb, past participle

VBP - Verb, non-3rd person singular present

VBZ - Verb, 3rd person singular present
```



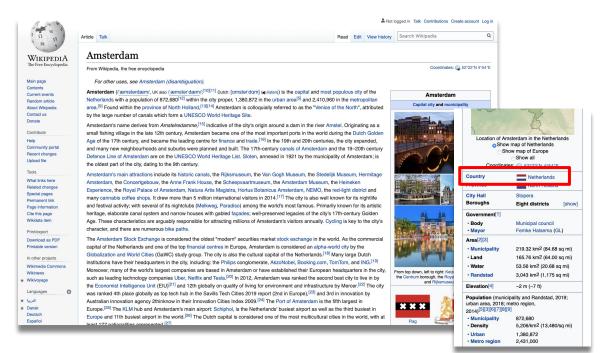


=> John's interesting book with a nice cover

REGEX

Muito útil para termos destacados por tags ou formatação

Ex.: HTML



```
Location of Ameterdam in the Netherlands
            Show map of Netherlands
               Show map of Europe
                     Show all
         Coordinates: $\infty$ 52°22'N 4°54'E
Country
                      Netherlands
Province
                       North Holland
City Hall
Boroughs
                     Eight districts
Government[1]
· Body
                     Municipal council

    Mayor

                     Femke Halsema (GL)
Area[2][3]

    Municipality

                     219.32 km2 (84.68 sq mi)

    Land

                      165.76 km2 (64.00 sq mi)
 · Water
                     53.56 km2 (20.68 sq mi)

    Randstar

                     3,043 km2 (1,175 sq mi)
                     -2 m (-7 ft)
Flevation[4]
Population (municipality and Randstad, 2019;
urban area, 2018; metro region,
2014)[5][3][6][7][8][9]

    Municipality

                     872,680

    Density

                     5,206/km2 (13,480/sq mi)

    Urban

                      1.380.872
 · Metro region
                     2,431,000
```

```
<div class="shortdescription nomobile noexcerpt noprint searchaux" style="display:none">Capital city and municipality in Nor
Holland, Netherlands</div>
▼ 
▼ 
 > >...
 > ...
 ...
 ...
 > ...
 > ...
 > ...
 ...
 ▼ 
  ▼ 
    <a href="/wiki/Country" title="Country">Country</a>
   > <span class="flagicon">...</span>
    <a href="/wiki/Netherlands" title="Netherlands">Netherlands</a> = $0
   > ...
 ...
  ...
```

```
>>> import re
>>> my_reg_exp = '<a [^>]+>(.*)</a>'
>>> line='<a href="/wiki/Netherlands" title="Netherlands">Netherlands</a>'
>>> print re.findall(my_reg_exp,line)
['Netherlands']
>>>
>>> line='<a href="/wiki/Spain" title="Spain">Spain</a>'
>>> print re.findall(my_reg_exp,line)
['Spain']
>>>
```

REGEX

Outros termos possuem uma estrutura muito peculiar

- Números de telefone
- CPF
- E-mails
- URLs
- etc.

Também é utilizado para capturar relações entre entidades

[PER], [POSITION] of [ORG]
[ORG] (named, appointed,...) [PER] Prep [POSITION]

o Nokia has appointed Rajeev Suri as President

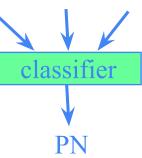
[ORG] headquarters in [LOC]

NATO headquarters in Brussels

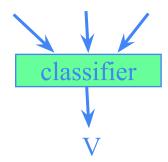
[ORG][LOC] (division, branch, headquarters...)

KFOR Kosovo headquarters

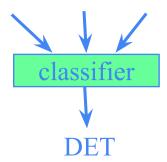
 Classificar cada token independentemente, mas utilizar como atributos as informações sobre os tokens na vizinhança (sliding window).



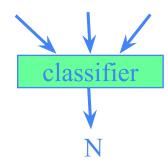
 Classificar cada token independentemente, mas utilizar como atributos as informações sobre os tokens na vizinhança (sliding window).



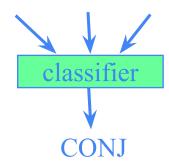
 Classificar cada token independentemente, mas utilizar como atributos as informações sobre os tokens na vizinhança (sliding window).



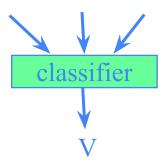
 Classificar cada token independentemente, mas utilizar como atributos as informações sobre os tokens na vizinhança (sliding window).



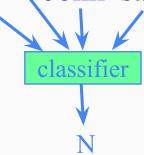
 Classificar cada token independentemente, mas utilizar como atributos as informações sobre os tokens na vizinhança (sliding window).

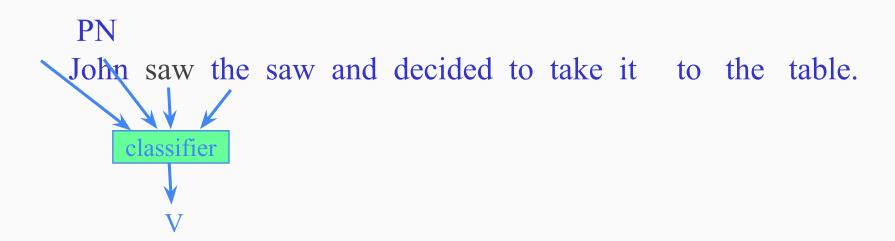


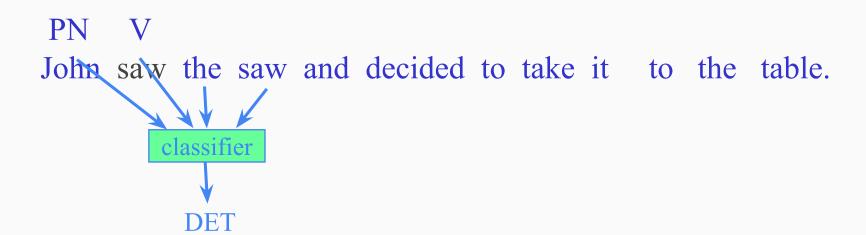
 Classificar cada token independentemente, mas utilizar como atributos as informações sobre os tokens na vizinhança (sliding window).

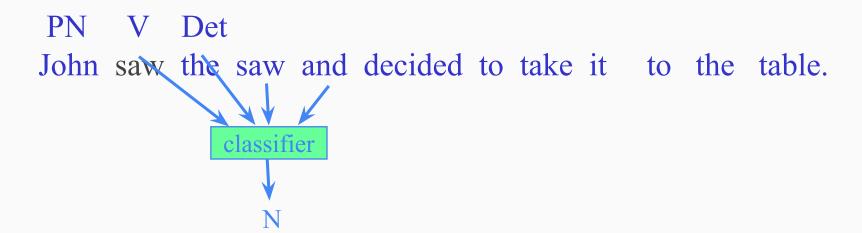


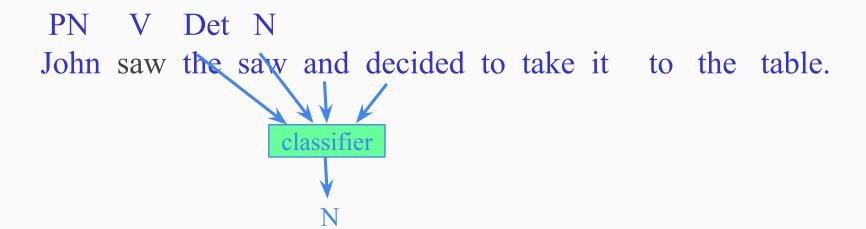
- Utilizar outputs (vizinhança) como inputs
- Seguir nas duas direções para ter melhor contexto







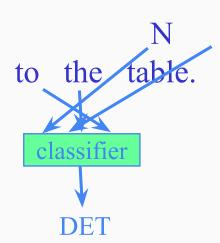


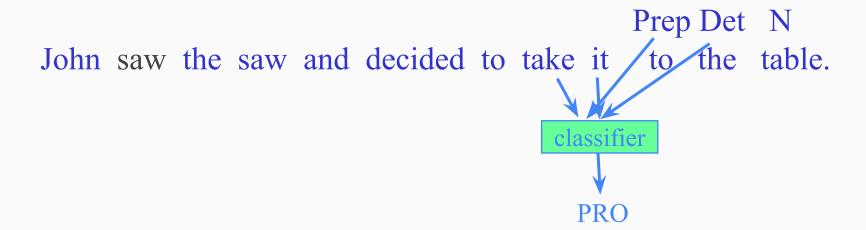


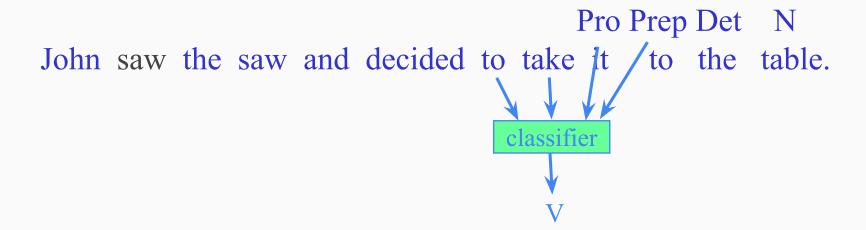
PN V Det N Conj V Part V Pro Prep Det N John saw the saw and decided to take it to the table.

classifier

John saw the saw and decided to take it







V Det V Conj V Part V Pro Prep Det N
John saw the saw and decided to take it to the table.

Forward+Backward Classification

```
FORWARD PN V Det N Conj V Part V Pro Prep Det N
John saw the saw and decided to take it to the table.

BACKWARD V Det V Conj V Part V Pro Prep Det N
John saw the saw and decided to take it to the table.
```

Features for Token Classification

- Token Features: características do próprio token.
- Local Features: características do contexto local (proximidades) do token atual.
- Global Features: características sobre a ocorrência do token em outros pontos do documento.
- Gazetteer Features: características extraídas das ocorrências do token em outras bases de dados

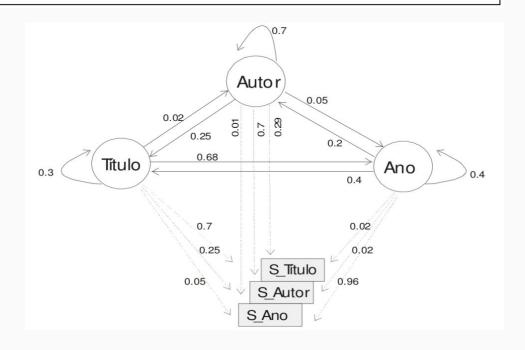
Sequence Labelling como classificação Limitações

- Integração de dados/labels não é tão simples
- Dificuldade de propagar incertezas e determinar, de forma conjunta, qual a classe mais provável de cada token

Modelos probabilisticos

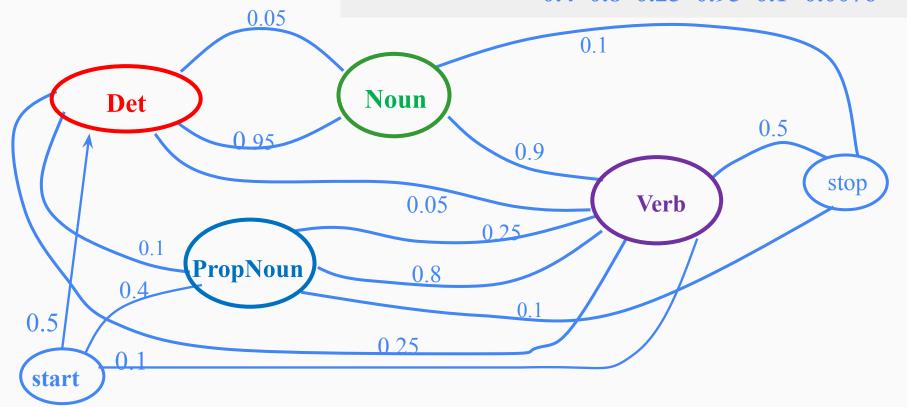
- Textos livres e semi-estruturados.
- Verifica a ocorrência de padrões em sequência no texto de entrada.
- Assume-se que a probabilidade de se visitar um estado depende do estado que foi visitado anteriormente.
- Maximiza a probabilidade de acerto para o conjunto todo de padrões.
- HMM, CRFs

R. C. Schank and R. P. Abelson, 1977, Scripts, Plans, Goals and Understanding, Lawrence Erlbaum Associates, New Jersey Sistema de EI Sistema de EI Título: Scripts, Plans, Goals and Understanding Jornal: Páginas: Editora: Lawrence Erlbaum Associates Local: New Jersey



HMM para POS

P(PropNoun Verb Det Noun) = 0.4*0.8*0.25*0.95*0.1=0.0076



Hidden Markov Model

- Modelo gerador probabilístico para sequências.
- Supõe um conjunto subjacente de estados ocultos (não observados) nos quais o modelo pode estar (por exemplo, classes gramaticais).
- Assume transições probabilísticas entre estados ao longo do tempo (por exemplo, transição de um POS para outro POS conforme a sequência é gerada).
- Supõe uma geração probabilística de tokens de estados (por exemplo, palavras geradas para cada POS).

Conditional Random Fields

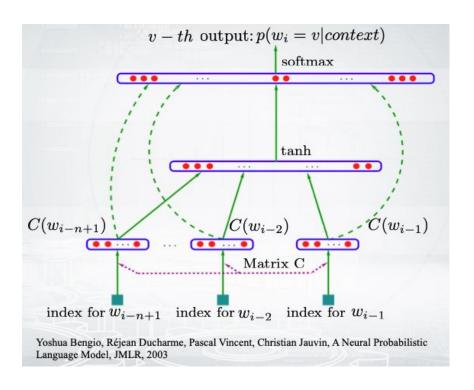
- Conditional Random Fields (CRFs) s\u00e3o modelos discriminativos especificamente projetados e treinados para rotulagem de sequência.
- Em geral, têm uma precisão superior em várias tarefas de rotulagem de sequência.
 - Noun phrase chunking
 - Named entity recognition
 - Semantic role labeling
- Modelos são mais complexos do que HMM, e mais custosos para treinar

DEMO

https://github.com/ufrpe-ensino/workshop-extracaao-informacao/blob/main/notebooks/01_Extracaolnformacao_CRF.ipynb

Neural Networks

Considerado estado da arte em sequence labelling



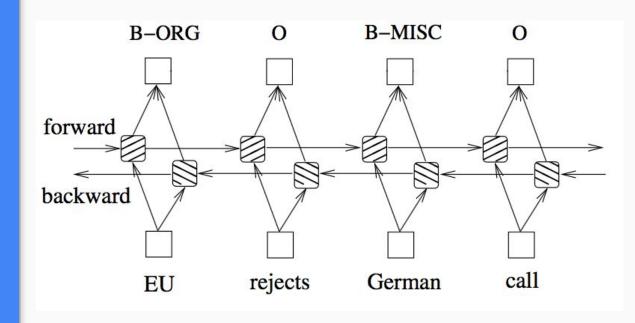
LSTM

LSTM - Long Short-Term Memory - é um tipo de Rede Neural Recorrente, com uma estrutura computacional mais complexa, que tem tido sucesso na resolução de tarefas sequenciais [Tai, 2015];

 Uma LSTM permite manter, alterar ou descartar informações anteriores para relacionar com uma informação atual;

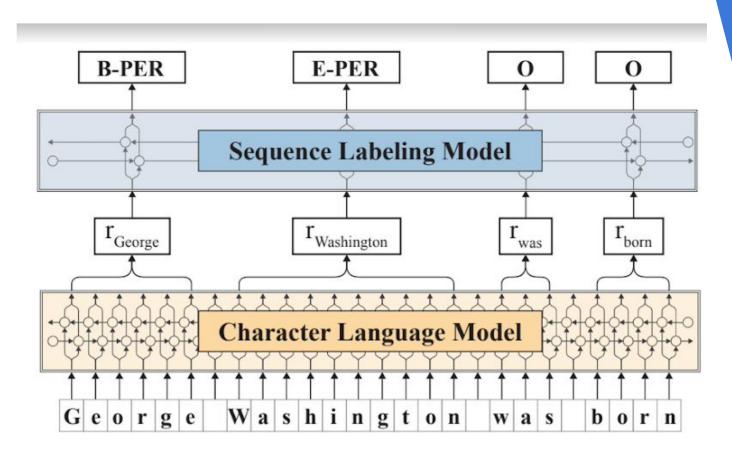
Há uma variação das redes LSTM, que são as Bidirectional LSTM (Bi-LSTM);

 As redes Bi-LSTM consistem de duas LSTM que funcionam em paralelo;



https://colah.github.io/posts/2015-08-Understanding-LSTMs/

FLAIR



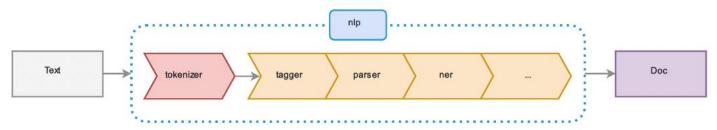
Frameworks para NER

spaCy flair

Spacy

Slides adaptados do curso Advanced NLP with Spacy

Spacy



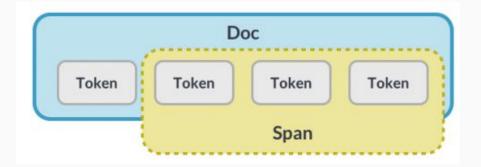


Features

- Support for 66+ languages
- 76 trained pipelines for 23 languages
- Multi-task learning with pretrained transformers like BERT
- Pretrained word vectors
- State-of-the-art speed
- Production-ready training system
- Linquistically-motivated tokenization
- Components for named entity recognition, part-of-speech tagging, dependency parsing, sentence segmentation, text classification, lemmatization, morphological analysis, entity linking and more
- Easily extensible with custom components and attributes
- Support for custom models in PyTorch, TensorFlow and other frameworks
- Built in visualizers for syntax and NER
- Easy model packaging, deployment and workflow management
- Robust, rigorously evaluated accuracy

Open Source
Foco em
desempenho e uso
industrial

Doc object



```
# Created by processing a string of text with the nlp object
doc = nlp("Hello world!")
# Iterate over tokens in a Doc
for token in doc:
    print(token.text)
```

```
Hello
world
!
```

Atributos Léxicos

```
doc = nlp("It costs $5.")
print('Index: ', [token.i for token in doc])
print('Text: ', [token.text for token in doc])
print('is_alpha:', [token.is_alpha for token in doc])
print('is_punct:', [token.is_punct for token in doc])
print('like_num:', [token.like_num for token in doc])
```

```
Index: [0, 1, 2, 3, 4]
Text: ['It', 'costs', '$', '5', '.']
is_alpha: [True, True, False, False, False]
is_punct: [False, False, False, True]
like_num: [False, False, False, True, False]
```

DEMOS!